

Predlog Projekta

Računarska Inteligencija 2025/26 | SV15/2023 Bojana Paunović

1. Naziv teme

Sistem za uklanjanje pozadinske buke iz govornih signala primenom algoritama veštačke inteligencije (*Audio Denoising*)

2. Definicija problema

Kada snimamo ili prenosimo govor u realnom okruženju, mikrofoni uvek hvataju i okolne zvukove (saobraćaj, muziku u pozadini, zvukove životinja...). Rezultat je signal u kome je glas izmešan sa bukom, što otežava razumevanje ili dalju obradu.

Cilj projekta je napraviti sistem koji na ulazu dobija takav zašumljeni audio, a na izlazu vraća samo čist govorni signal, bez pozadinske buke. Ovo je problem koji se u literaturi zove *speech enhancement* ili *audio denoising*.

Primeri gde bi ovakav sistem bio koristan:

- Video pozivi (Zoom, Teams) – automatsko uklanjanje buke bez skupog mikrofona
- Glasovni asistenti – bolji ulaz znači tačniju transkripciju govora
- Restauracija starih snimaka degradiranih šumom
- Slušni aparati i asistivne tehnologije za osobe sa oštećenjem sluha

3. Skup podataka

3.1 DNS Challenge skup podataka

Koristiću DNS Challenge (*Deep Noise Suppression*) skup podataka koji je objavio Microsoft Research. To je standardni, javno dostupan skup namenjen upravo ovom problemu – sadrži i čiste govorne snimke i snimke raznih buka, što omogućava pravljenje parova (zašumljeni ulaz → čist izlaz) za nadzirano učenje (*supervised learning*).

- Čisti govorni snimci: ~500 sati, različiti govornici, naglasci i jezici (engleski, ali i drugi)
- Snimci buke: ~180 sati – saobraćaj, kancelarija, muzika, zvukovi prirode
- Format: WAV fajlovi, 16.000 uzoraka u sekundi (16 kHz), mono (jedan kanal)
- Parovi se prave sintetički: čist govor + buka. Mešaju se na kontrolisanom SNR nivou

Link: <https://github.com/microsoft/DNS-Challenge>

SNR (*Signal-to-Noise Ratio*) je odnos jačine govora i jačine buke izražen u decibelima. SNR od 0 dB znači da su glas i buka jednako glasni. Što je SNR manji (negativan), to je buka glasnija od govora i problem je teži.

3.2 Atributi skupa podataka

Atribut	Šta predstavlja	Uloga
noisy_speech	Mešavina govora i buke – ono što mikrofoni snima u realnosti	Ulaz modela (X)
clean_speech	Originalni čist govor bez buke – ono čemu težimo	Ciljno obeležje (Y)
noise_type	Vrsta buke (saobraćaj, muzika, šum uređaja...)	Metapodatak za analizu
snr_db	Odnos jačine govora i buke u dB, od -5 do 30	Metapodatak za stratifikovanu evaluaciju (evaluacija po grupama podataka)
speaker_id	Oznaka govornika iz originalnog skupa	Metapodatak za analizu generalizacije

Ciljno obeležje je `clean_speech` – kontinualni audio signal koji model treba da rekonstruiše iz `noisy_speech` ulaza. Model ne bira između unapred definisanih klasa, već predviđa numeričke vrednosti.

4. Metodologija

4.1 Predobrada – pretvaranje zvuka u sliku

Neuronska mreža ne može direktno da obrađuje sirovi audio signal. Umesto toga, audio se pretvara u 2D reprezentaciju sličnu slici, pa se primenjuju tehnike iz oblasti obrade slike.

Koraci predobrade:

- 1. STFT (*Short-Time Fourier Transform*):** Audio signal se seče na kratke okvire (prozore) od 512 uzoraka i za svaki se računa Furijeova transformacija. Rezultat je spektrogram – 2D matrica gde jedna osa predstavlja vreme, a druga frekvenciju. Na ovaj način vidimo koje frekvencije su prisutne u svakom trenutku.
- 2. Magnitude i faza:** STFT daje kompleksne brojeve. Delimo ih na magnitude (koliko je jaka svaka frekvencija) i fazu (informacija o talasnom obliku). Model obrađuje samo magnitude, a fazu čuvamo za rekonstrukciju.
- 3. Log-kompresija:** Primenjujemo $\log(1 + \text{magnitude})$ da bismo smanjili dinamički opseg vrednosti – inače bi tihi zvuci imali zanemarljive vrednosti u poređenju sa glasnim, što otežava učenje.
- 4. Normalizacija:** Oduzimamo srednju vrednost i delimo standardnom devijacijom (*z-score* normalizacija). Ovo ubrzava konvergenciju modela.
- 5. Segmentacija:** Audio snimci se dele na segmente dužine 2 sekunde. Susjedni segmenti se preklapaju 50%, odnosno svaki novi segment počinje 1 sekundu nakon prethodnog. Ukoliko je snimak kraći od 2 sekunde, na njegov kraj se dodaju nule kako bi svi segmenti imali istu dužinu.

4.2 Arhitektura modela – U-Net sa LSTM

Koristiću U-Net arhitekturu – originalno razvijenu za segmentaciju medicinskih slika, ali se odlično pokazala i za audio obradu. Ideja je da mreža "nauči da uklanja" buku iz spektrograma, kao što bi to radila u slučaju uklanjanja šuma sa slike.

Enkoder ("kompresija" – mreža uči šta je važno):

- 5 konvolucionih blokova, svaki sadrži: Conv2D → Batch Normalization → LeakyReLU
- Nakon svakog bloka dimenzije ulaznih podataka se smanjuju za polovinu (*stride* = 2), dok se broj filtera povećava sa 16 na 32, 64, 128 i 256. Na taj način mreža postepeno sažima spektrogram i zadržava najvažnije informacije
- Konvolucionni slojevi uče da prepoznaju lokalne obrasce u spektrogramu, kao što su karakteristične frekvencije ljudskog glasa i različite vrste pozadinske buke

Batch Normalization normalizuje aktivacije unutar mreže tokom treniranja – stabilizuje učenje. LeakyReLU je aktivaciona funkcija koja uvodi nelinearnost (bez nje bi cela mreža bila linearna transformacija).

Bottleneck – LSTM sloj ("razumevanje konteksta"):

- Bidirekcionni LSTM, 2 sloja, 512 *hidden units* po smeru
- LSTM je tip rekurentne mreže koja pamti informacije kroz vreme. Ovo je važno jer govor ima temporalnu strukturu – zvuci zavise od onoga što je došlo i pre i posle
- Bidirekcionalnost znači da mreža gleda i unazad i unapred u audio sekvenci

Konvolucija vidi samo lokalni kontekst (prozor 3×3). LSTM u *bottleneck*-u omogućava da model uzme u obzir širi vremenski kontekst pri odluci šta je glas, a šta buka.

Dekoder ("rekonstrukcija" – mreža vraća detalje):

- Sastoji se od 5 blokova sa transponovanim konvolucijama, koji predstavljaju obrnutu strukturu enkodera
- Njihov zadatak je da postepeno povećavaju rezoluciju podataka i rekonstruišu očišćeni spektrogram
- Između odgovarajućih slojeva enkodera i dekodera koriste se skip konekcije

Skip konekcije predstavljaju ključni element U-Net arhitekture. Tokom procesa kompresije u enkoderu može doći do gubitka određenih detalja signala. Skip konekcije prenose te informacije direktno iz enkodera u odgovarajuće slojeve dekodera, čime omogućavaju precizniju rekonstrukciju audio signala. Zahvaljujući njima, model bolje čuva karakteristike govora i efikasnije uklanja šum.

Izlaz – maskiranje:

- Poslednji sloj daje masku $M \in [0, 1]$ iste veličine kao ulazni spektrogram
- Čist spektrogram = $M \times \text{ulazni_spektrogram}$ (svaka vrednost se množi maskom)
- Maska blizu 1 = "ovo je glas, zadrži". Maska blizu 0 = "ovo je buka, ukloni"
- Na kraju, čist spektrogram + originalna faza → iSTFT → rekonstruisani audio signal

Maskiranje je bolji pristup od direktne predikcije čistog spektrograma jer je mreži lakše da nauči šta da ukloni nego da halucinira čitav signal od nule.

4.3 Loss funkcija – kako merimo grešku tokom treniranja

Loss funkcija predstavlja meru greške modela tokom treniranja. Cilj je da se njena vrednost što više smanji, čime se poboljšava kvalitet rekonstruisanog audio signala.

U projektu će se koristiti kombinacija dve loss funkcije:

- **SI-SDR loss** meri sličnost između rekonstruisanog i originalnog čistog govornog signala, nezavisno od njihove glasnoće. Veća vrednost SI-SDR ukazuje na bolji kvalitet rekonstrukcije, pa se tokom treniranja koristi njegova negativna vrednost kako bi se greška minimizovala.
- **Multi-resolution STFT loss** poredi spektrograme rekonstruisanog i originalnog signala na više vremensko-frekventnih rezolucija. Na taj način model uči da očuva i kratkotrajne i dugotrajne karakteristike govora.

Ukupna funkcija greške dobija se kombinovanjem ove dve komponente:

$$L = -\text{SI-SDR} + 0.1 \cdot \text{STFT}_{\text{loss}}$$

4.4 Trening

- Optimizer: AdamW (lr = 1e-3, weight_decay = 1e-4) – adaptivni optimizator, standardan izbor za ovakve mreže
- Raspored učenja: prvih 5 epoha postepeno raste (*warmup*), zatim polako opada po kosinusnoj krivi do kraja treninga
- Batch size: 16 segmenata od 2 sekunde po iteraciji
- Broj epoha: maksimalno 100, sa *Early Stopping* mehanizmom – ako se validacioni SI-SDR ne poboljša 10 epoha zaredom, trening se prekida
- Data augmentation: pri svakom učitavanju, SNR se nasumično menja ± 3 dB da bi model bio robusniji

5. Način evaluacije

5.1 Podela skupa

- Trening skup (80%): koristi se za ažuriranje težina mreže
- Validacioni skup (10%): prati se tokom treninga za *Early Stopping* i podešavanje parametara – model ga nikad ne "uči"
- Test skup (10%): koristi se samo jednom, na kraju, za konačnu ocenu – nema povratnog uticaja na model
- Sve tri particije su disjunktne po speaker_id: nijedan govornik iz validacije/testa nije bio u treningu

5.2 Metrike evaluacije

Metrika	Šta meri i zašto se koristi	Opseg
PESQ	<i>Perceptual Evaluation of Speech Quality</i> – ITU-T standard koji simulira kako čovek percipira kvalitet govora. Standardna metrika u telekomunikacijama.	-0.5 do 4.5, viši = bolji
STOI	<i>Short-Time Objective Intelligibility</i> – meri koliko je govor razumljiv, ne samo kvalitetan. Važno jer signal može zvučati "čisto" a biti nerazumljiv.	0 do 1, viši = bolji
SI-SDR	<i>Signal-to-Distortion Ratio</i> – čisto matematička mera sličnosti rekonstruisanog i referentnog signala.	dB, viši = bolji
Δ SNRi	Poboljšanje SNR-a: razlika između SNR-a pre i posle denoising-a. Pozitivna vrednost znači da smo poboljšali odnos signal/buka.	dB, pozitivno = bolje

5.3 Baseline poređenje

Rezultati mreže biće upoređeni sa klasičnim metodama koje ne koriste duboko učenje:

- **Spektralno oduzimanje (*Spectral Subtraction*)**: procenjuje spektr buke iz tihih segmenata i oduzima ga od zašumljenog spektrograma. Jednostavno, ali loše radi na nestacionarnoj buci.
- **Wiener filter**: optimalni linearni filter koji minimizuje srednju kvadratnu grešku između čistog i procenjenog signala. Bolji od spektralnog oduzimanja, ali i dalje ograničen linearnim pretpostavkama.

Cilj je da U-Net nadmaši obe metode, posebno na niskim SNR nivoima (ispod 5 dB) gde linearni pristupi otkazuju.

6. Tehnologije

Tehnologija	Šta je i zašto se koristi
Python 3.10	Programski jezik – standardni izbor za ML projekte zbog bogatog ekosistema biblioteka
PyTorch 2.x	Framework za duboko učenje – omogućava definisanje i trening neuronskih mreža. Koristi se za implementaciju U-Net arhitekture, LSTM sloja i loss funkcija.
torchaudio	PyTorch proširenje za audio – sadrži gotove implementacije STFT, iSTFT i učitavanja WAV fajlova, kompatibilne sa PyTorch tensorima
librosa	Python biblioteka za audio analizu – koristi se za vizualizaciju spektrograma i pripremu podataka tokom istraživanja
pesq	Python wrapper za ITU-T P.862 standard – jedini način da se izračuna PESQ metrika u Pythonu
pystoi	Python implementacija STOI metrike – meri razumljivost govora
NumPy / SciPy	Fundamentalne biblioteke za numeričke operacije i rad sa nizovima
Matplotlib	Vizualizacija – grafici krivih treninga (loss, metrike po epohama), prikaz spektrograma pre/posle
Weights & Biases	Alat za praćenje eksperimenata – automatski loguje metrike, gubitke i parametre tokom treninga, dostupno preko web interfejsa

7. Primeri gotovih rešenja

- DeepFilterNet – open-source model za filtriranje govora, sličan pristup (masking u spektralnom domenu), dobri rezultati na DNS benchmarku

<https://github.com/Rikorose/DeepFilterNet>

- Facebook Denoiser – model koji radi direktno u vremenskom domenu (bez STFT), razvijen od Meta AI istraživača

<https://github.com/facebookresearch/denoiser>

- Microsoft DNS Challenge baseline – referentni modeli (DTLN, PoCoNet) na istom skupu podataka koji će se koristiti u ovom projektu

<https://github.com/microsoft/DNS-Challenge>

8. Relevantna literatura

- Ronneberger et al. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation – originalni rad koji uvodi U-Net arhitekturu

<https://arxiv.org/abs/1505.04597>

- Choi et al. (2019). Phase-Aware Speech Enhancement with Deep Complex U-Net – primena U-Net-a na speech enhancement

<https://arxiv.org/abs/1903.03107>

- Reddy et al. (2021). INTERSPEECH 2021 Deep Noise Suppression Challenge – opis DNS skupa i benchmark rezultati

<https://arxiv.org/abs/2101.01902>

- Taal et al. (2011). An Algorithm for Intelligibility Prediction of Time-Frequency Weighted Noisy Speech – originalni rad za STOI metriku

<https://doi.org/10.1109/TASL.2011.2114881>

- ITU-T Recommendation P.862 (2001). Perceptual evaluation of speech quality (PESQ) – standard za PESQ metriku

<https://www.itu.int/rec/T-REC-P.862/en>

- Défossez et al. (2020). Real Time Speech Enhancement in the Waveform Domain

<https://arxiv.org/abs/2006.12847>